Задание 1

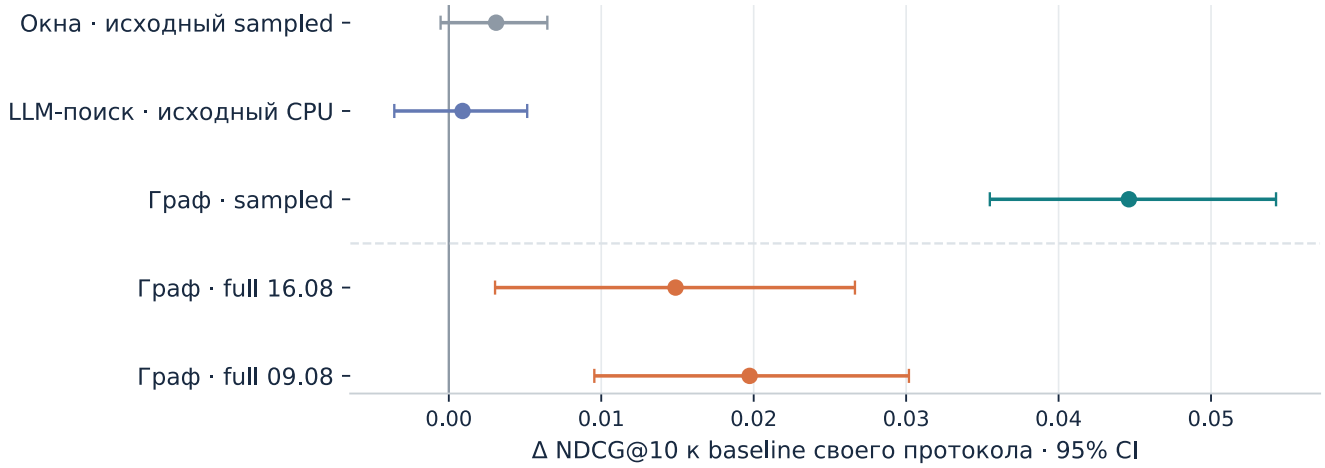
Автоматизация признаков для рекомендаций

Ручные агрегаты, поиск преобразований и обучаемые связи в графе взаимодействий.

KION · полные истории выбранных пользователей · 25 октября 2026

основная / расширенная популяция: **50k / 200k**; обучаемых графовых признаков: **16**; проверки полного каталога: **2 недели**.

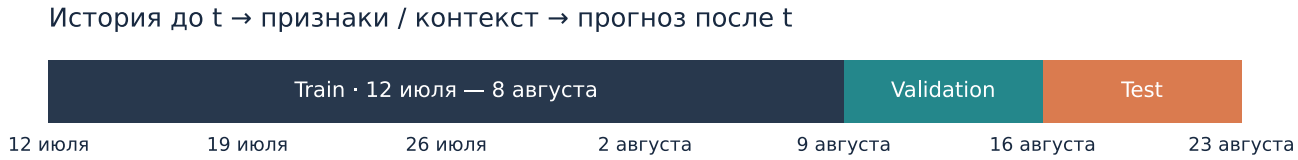
Поиск окон изменил NDCG@10 с **0,46107** до **0,46417**. Основной доверительный интервал пересекает ноль. Устойчивое преимущество LLM перед случайным поиском не установлено. Дополнительные графовые признаки повысили качество; полный каталог проверен отдельно на двух периодах с более ранним validation.



Основные окна/LLM-поиск и дополнительные графовые проверки. Разницы считаются к baseline своего протокола; candidate pools и популяции различаются, абсолютные NDCG между ними не сопоставимы. CI — bootstrap пользователей; окна и граф усреднены по трём запускам CatBoost, LLM-поиск CPU выполнен один раз.

Постановка и сильный baseline

Для пользователя с историей в начале недели ранжируем объекты следующей недели. Кандидаты включают все доступные позитивы и до 100 синтетических негативов. Просмотренные объекты исключены; каталог строится только по прошлому.



Каждый признак использует только события timestamp < t. Четыре train snapshot, отдельные validation и test. История для агрегатов начинается до показанного участка.

Содержательный ручной baseline

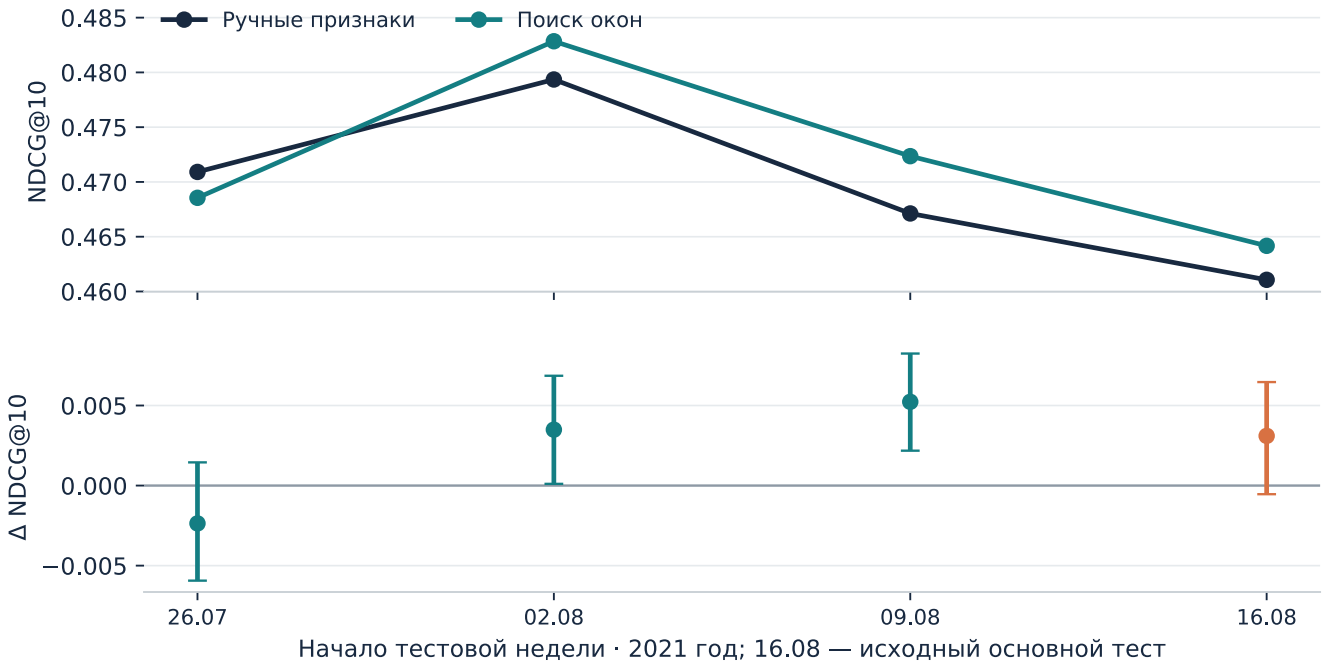
CatBoost: depth 6, learning rate 0,07, L2 = 5, до 350 итераций с early stopping. Пользовательские и объектные категории, counts, средняя доля просмотра, recency, доли и тренды; связи user–item, user–genre и user–director. Ручные окна: 7, 30, 90 дней и вся история.

Метод	Признаки	NDCG@10	Recall@10
Ручной CatBoost	74	0,46107	0,60046
Поиск окон	186	0,46417	0,60152
Без косвенных связей[1]	48	0,43581	0,57315
Популярность за 7 дней[1]	1	0,43307	0,58208

Manual и поиск окон — средние трёх запусков. [1] Абляция и популярность — один запуск. Test: 1480 запросов; 157 позитивов новых объектов не входят в известный каталог, 20 полностью холодных групп исключены. Это условное ранжирование; метки и LogLoss не являются CTR.

Устойчивость во времени

Дополнительные окна 2, 3, 5, 10, 14, 21, 45 и 60 дней генерируются автоматически. Важности ранжируют блоки; validation выбирает top-1/top-2/top-4 или все окна. Для временной проверки тот же алгоритм переобучен на трёх более ранних периодах.



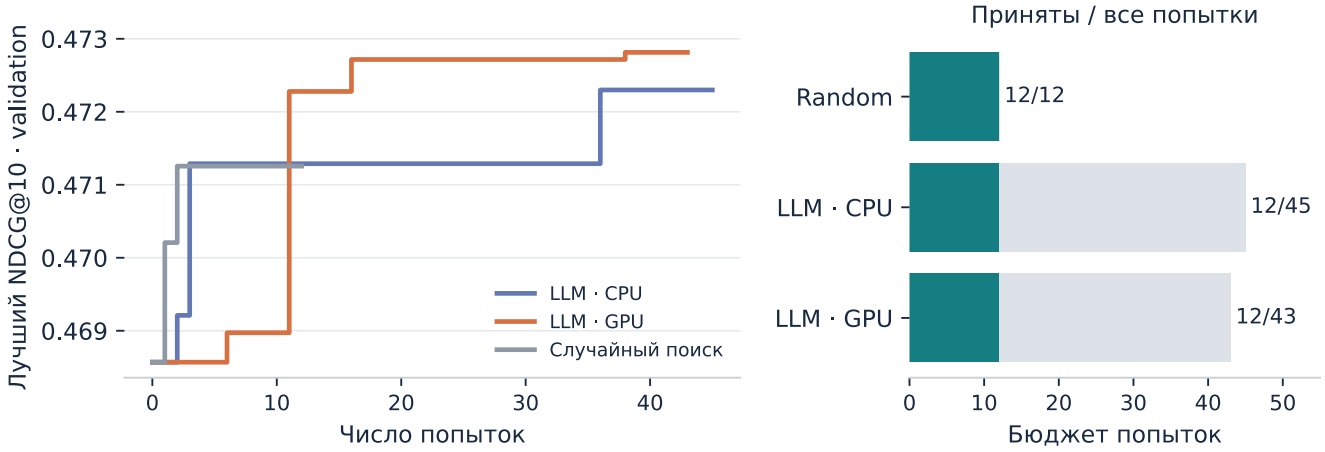
Верх: средний NDCG по трём запускам. Низ: парная разница auto − manual с 95% CI. Даты 26.07, 02.08 и 09.08 — дополнительный ретроспективный анализ; 16.08 — исходный основной тест.

Test-неделя	Manual	Auto	Δ NDCG	95% CI	Признаки
26.07	0,47091	0,46855	-0,00236	[-0,00594; 0,00145]	130
02.08	0,47935	0,48284	0,00349	[0,00011; 0,00686]	88
09.08	0,46712	0,47235	0,00523	[0,00218; 0,00825]	102
16.08	0,46107	0,46417	0,00310	[-0,00054; 0,00646]	186

Грамматика, настройки и правила кандидатов зафиксированы до дополнительных запусков. Выбор использует только предшествующий validation. В этой процедуре обязательно добавляется хотя бы один блок окон; отказ к manual не разрешён. Пользователи и train-периоды перекрываются, недели не независимы.

Что дала генерация признаков

Поиск выражений строит новые признаки из временных агрегатов KION. Qwen2.5-Coder-1.5B-Instruct предлагает выражения; CatBoost возвращает validation NDCG. Ответы переводятся из ограниченной математической записи в RPN, без исполнения сгенерированного Python.



Слева — лучший отдельный кандидат на validation по числу попыток, не финальная test-метрика. Справа: бирюзовые части — принятые ответы, серые — отклонённые. Бюджет принятия одинаков: 12 кандидатов.

Метод	Признаки	NDCG@10	Recall@10
Manual	74	0,45886	0,60055
Random	75	0,46132	0,59962
LLM-поиск · CPU	75	0,45976	0,59861
LLM-поиск · GPU	77	0,46405	0,59976

На CPU LLM − random = **−0,00155**, CI [−0,00518; 0,00230]. На GPU разница **+0,00273**, CI [−0,00182; 0,00716]. Более удачный GPU-набор не заменял основной CPU-результат. Преимущество перед random не подтверждено.

GPU LLM-поиск − manual: +0,00519, CI [0,00059; 0,00954]; это отдельный набор предложений, без подтверждённого выигрыша над random.

Настройки: временной holdout, CatBoost/NDCG, локальная Qwen, бюджет 12 и выбор top-1/3/5 выражений. Strict-RPN дал 0/48 валидных ответов на CPU и GPU; infix — 12/45 и 12/43.

Итоги исходного сравнения

Объяснение результата

Ручные признаки уже покрывают несколько масштабов времени и косвенные связи. Новые окна коррелируют с существующими. Арифметические преобразования не добавляют новую историю; выигрыш зависит от явных взаимодействий, квантования и регуляризации деревьев. В полном KION нет повторных строк user–item, поэтому прямые связи при исключении просмотренного почти бесполезны.

Поиск выражений требует генерации кандидатов и повторного обучения CatBoost. При большом каталоге материализация признаков для всех пар ограничивает масштабируемость.

Ограничения и воспроизведение

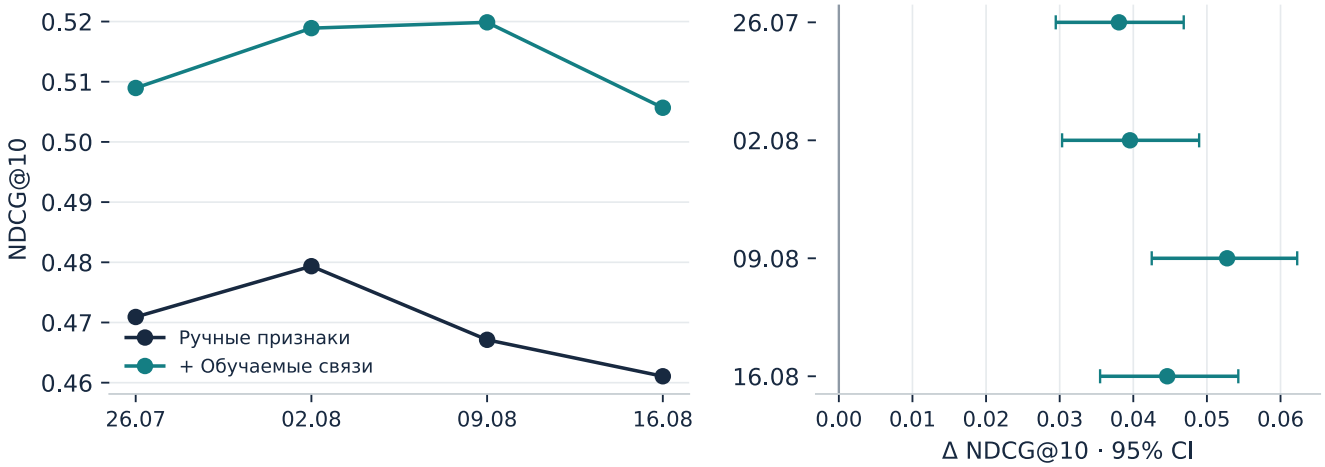
- KION хранит агрегированную пару и last_watch_dt, а не полный поток просмотров; исторических снимков метаданных нет.
- Условные кандидаты с включёнными позитивами не измеряют end-to-end retrieval и онлайн-эффект.
- Сэмпл меньше полной базы; несколько временных окон не устраняют validation overfitting и вариативность LLM-поиска.

Полная установка и команды: README. Подробные таблицы: основной эксперимент, GPU LLM-поиск. Код и версии исходников включены в архив.

Связи, которые модель извлекает из истории

Временные окна перестраивают известные агрегаты. Другой источник информации — совместное потребление: граф user–item может связать объекты даже при несовпадающих жанрах и режиссёрах.

Для каждого snapshot учим SVD на бинарной и нормированной матрице истории. Dot/cosine сходства при 16/32/64 координатах дают 12 признаков. Ещё четыре — сумма и среднее item-neighbour сходства top-50/200. Каталог, пользователи и связи берутся строго до cutoff; target labels не участвуют.



Средние по трём запускам CatBoost, одинаковые кандидаты. Правые интервалы — bootstrap пользователей после усреднения повторных запусков. Все дополнительные проверки ретроспективны; недели и пользователи перекрываются.

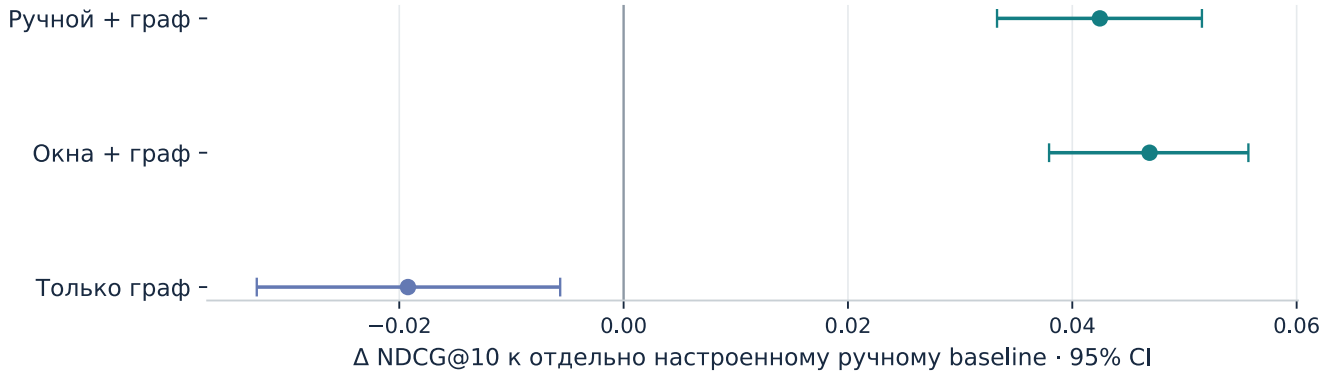
Признаки	Validation NDCG
Ручные признаки	0,46857
+ Binary SVD	0,50183
+ Normalized SVD	0,47997
+ Item neighbours	0,51488
+ Все 16 признаков	0,51878

> Validation выбрала все 16 признаков: всего 90 вместо 74. На исходном test NDCG **0,50568** против 0,46107; Δ **+0,04461**, CI [0,03549; 0,05426].

Это расширение выполнено после обсуждения основного test. Более сильный дополнительный результат не заменяет исходные окна/LLM-поиск. Граф фиксирован; в трёх запусках повторно обучается только CatBoost.

Проверка против настроенного baseline

Чтобы проверить, не объясняется ли выигрыш слабой настройкой baseline, каждой группе дали одинаковые четыре варианта: Logloss или YetiRank, глубина 4 или 6. До 500 деревьев, learning rate 0,07, L2=5; early stopping и выбор настройки используют validation NDCG@10.



Каждое семейство выбирает настройку отдельно по validation, затем оценивается в трёх повторных запусках. Ни objective, ни глубина не выбираются по test. Интервалы условны на исследованный grid и те же test-запросы.

Семейство	Признаки	Loss / depth	NDCG@10	Recall@10
Ручной	74	Logloss / 4	0,46005	0,59954
Ручной + граф	90	Logloss / 4	0,50250	0,64957
Окна + граф	202	Logloss / 6	0,50694	0,64955
Только граф	16	YetiRank / 6	0,44082	0,59497

Что теперь можно заключить

Обучаемые collaborative-сходства добавляют информацию о косвенных предпочтениях. Это содержательно отличается от перебора коррелирующих временных окон. Численные признаки позволяют использовать граф в обычном бустинге без user-ID и без ручного перечисления всех связей между категориями.

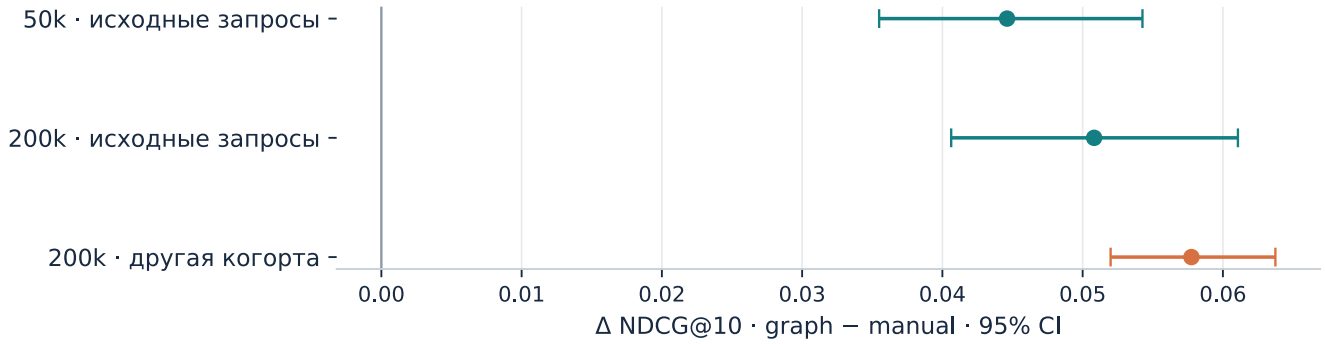
Новые сравнения относятся к тому же уже рассмотренному тесту. Отдельная настройка семейств, размер grid и более позднее начало исследования ограничивают подтверждающую силу CI. Для следующего этапа нужны новые пользователи/периоды с заранее замороженной процедурой.

```
python -m task1.relational
python -m task1.relational_temporal
python -m task1.ranking_study
```

Полные CSV, протоколы и интервалы: приложение об улучшениях. Параметры расчёта сохранены для каждого временного среза.

Больше истории и другие оценочные пользователи

Граф может лучше оценивать связи при большем числе исторических пользователей. К исходным 50 000 добавлены 150 000 случайных пользователей; сохранена вся доступная история. Одинаковый расширенный лог доступен и ручным агрегатам, и графу.



В первых двух строках supervised train/validation queries и test-кандидаты идентичны. В третьей — другая когорта оценочных пользователей и каталог 200k; внутри строки сравнение парное. Средние трёх запусков CatBoost; недели/источник данных общие.

Оценка / история	Manual	Graph	Δ NDCG
50k · исходные запросы	0,46107	0,50568	0,04461
200k · исходные запросы	0,46667	0,51749	0,05082
200k · другая когорта	0,47461	0,53237	0,05776

200 000 пользователей дают **1 136 830** строк истории. Пиковое потребление памяти ≈2,59 GiB. Расход памяти определяется материализацией признаков для всех пар.

Отдельная оценочная когорта

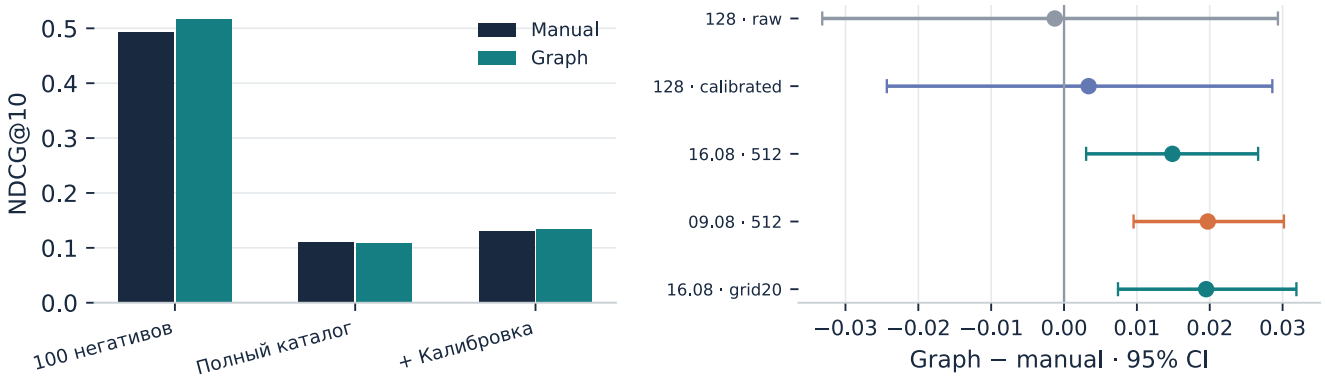
Те же сохранённые модели оценены на **4920** дополнительных пользователях вне исходных 50k. Их размеченные запросы не участвовали в обучении или выборе. Прошлые взаимодействия разрешены в графе и агрегатах — это warm/transductive проверка, без нового fit или отбора.

В отдельной когорте каталог шире; её абсолютный NDCG нельзя напрямую сравнивать с исходными запросами. Сопоставимы manual и graph внутри каждой строки. Та же неделя и уже изученный KION ограничивают независимость подтверждения.

```
python -m task1.population_study
python -m task1.cohort_study
```

Проверяем полный каталог

Выигрыш на условном пуле не гарантирует выигрыш во всей выдаче. Для 128 случайных пользователей перечислены все известные объекты за исключением прошлой истории: 1,47 млн пар. Состав кандидатов не зависит от target; те же frozen модели оцениваются без дообучения.



Слева: изменение протокола на одних пользователях резко снижает абсолютный NDCG. Справа: парные разницы методов; первые 128 дают широкие CI. Коэффициенты из validation заморожены до оценки дополнительной группы 512.

> На первых 128 пользователях сырой score не подтвердил преимущество graph. Поэтому условный выигрыш нельзя автоматически переносить на полный каталог: важны распределение кандидатов и неопределённость оценки.

Отдельный validation full-catalog выбрал score + α·log(1+past item count), одинаковый grid α=0/0,1/0,25/0,5/1. Manual: α=0,50, graph: α=0,25. Эвристика меняет баланс с популярностью; это не точная коррекция propensities.

Test · 512 users	Manual NDCG	Graph NDCG	Δ / 95% CI
09.08	0,15540	0,17513	0,01973 / [0,00955; 0,03018]
16.08	0,13073	0,14560	0,01487 / [0,00303; 0,02664]
16.08 · grid20	0,11968	0,13918	0,01950 / [0,00741; 0,03190]

Для 16.08 замороженная калибровка дала Δ **0,01487**. Для 09.08 модели заново обучены на правильном более раннем split, а α выбрана на 02.08, без переноса коэффициентов из будущего. Новые test/validation пользователи не пересекаются с прежними full-catalog группами.

Grid20: graph half-life ∞/10/21/60 × 5α против manual L2=1/5/20/100 × 5α, по 20 validation вариантов. Выбраны ∞ и L2=5; ещё одна отдельная когорта из 512 пользователей. Затухание не улучшило validation.

Это тот же исследованный KION и ретроспективный выбор метода. Full-catalog 512: 5,89 млн пар, peak RSS≈8,58 GiB. Сдвиг negative distribution требует согласованного candidate protocol; полный перебор и materialization ограничивают масштаб.