Задание 2

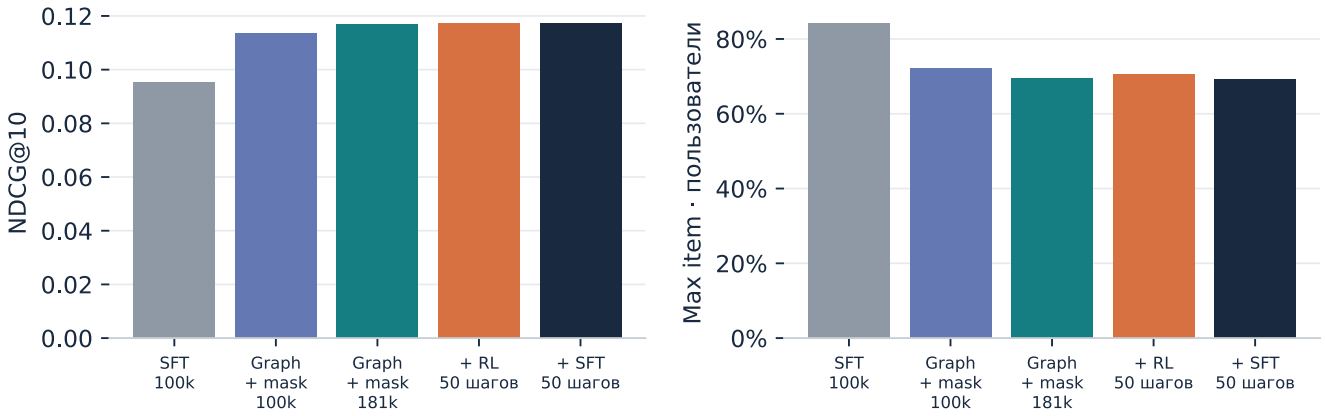
Рекомендации после обучения с подкреплением

Как оптимизация предсказанного вознаграждения меняет релевантность, концентрацию и многошаговую генерацию.

KION · полные истории выбранных пользователей · 25 октября 2026

NDCG CPU · SFT + маска: **0,11680**; R^2 более информативной watch RM: **0,166**; AUC новой return-proxy RM: **0,644**.

Маска усиливает исходную SFT; дополнительный эффект graph init зависит от повторного обучения и протокола. Fixed200 RL не проходит строгий validation-отбор. **Ранняя остановка позволяет небольшой рост proxy при близкой релевантности**; убедительный выигрыш точности или удержания не установлен.



Здесь CPU: одинаковые test users/targets и каталог; SFT обучена один раз, RL и matched контроль — по три раза при fixed SFT/RM. Method/step выбраны по validation. Отдельно — 18 GPU SFT fits: masked gain графа слабее. Все дополнения exploratory.

Исходный эксперимент и протокол

На полном KION равномерно выбраны 50 000 пользователей, сохранены все 285 343 события. Для обучения используются 100 000 переходов, для validation/test — по 2000 пользователей. Словарь из 8029 train-объектов фиксируется до 9 августа; 8,25% test-targets холодные и считаются промахами.

Период	Даты	Назначение
Train	13.03 — 08.08.2021	SFT и reward model
Validation	09.08 — 15.08.2021	Checkpoint и исходный выбор RL
Test	16.08 — 22.08.2021	Итоговая оценка

Все targets одного дня видят только прошлые дни. Порядок ID внутри прошлых дней технический: настоящая внутридневная последовательность неизвестна.

Базовая политика

Компактная GPT-2 с нуля: 2 блока, hidden size 64, 4 heads, контекст до 32 item-ID, causal attention, learned positions и tied output head. Checkpoint выбирается по validation NDCG.

RL-дообучение

On-policy REINFORCE, 4 независимые траектории на контекст, leave-one-out baseline. 200 обновлений; доступны exact KL к SFT, CE на реальных переходах и horizon 1/5.

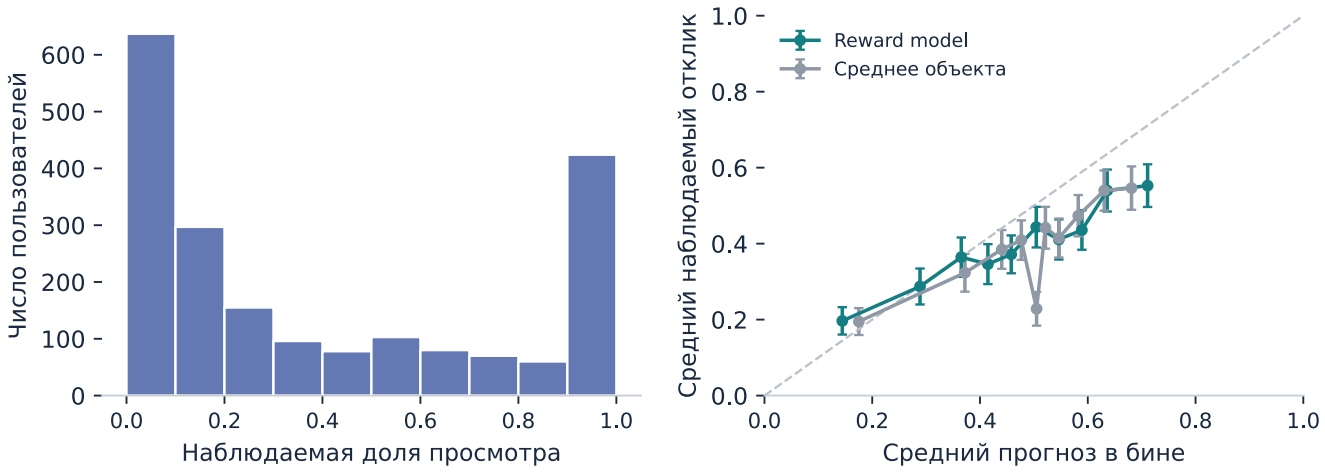
Политика	NDCG@10	Recall@10	Watch-proxy	Покрытие
Исходная GPT-2	0,09537	0,16450	0,50813	5,4%
RL без ограничений	0,09360	0,16450	0,57794	2,5%
RL · KL 0,1	0,09408	0,16250	0,53678	5,6%
RL · KL 1	0,09499	0,16250	0,52648	5,6%
Balanced · 5 шагов	0,09211	0,15750	0,54293	5,4%
Return · 5 шагов	0,09086	0,15750	0,52862	5,8%
Продолженное SFT	0,09298	0,15950	0,49991	5,7%

Полный train-каталог, без добавления target в упрощённый пул. Validation выбрала balanced five-step по максимальному watch-proxy при NDCG ≥95% SFT. На test исходный выбор не менялся. Continued-SFT контроль не участвовал в выборе.

Насколько надёжно вознаграждение

Reward model использует embedding кандидата, среднее и последнее представления истории и их взаимодействие. Две головы предсказывают долю просмотра и наличие следующего активного дня в пределах трёх суток. Пропуски просмотра маскируются; неполные return-окна цензурируются.

Модель	MAE	RMSE	R^2
Reward model	0,33567	0,37870	0,012
Среднее объекта	0,34490	0,38337	—
Общее среднее	0,36762	0,39681	—
Независимая инициализация	0,35152	0,39597	-0,080



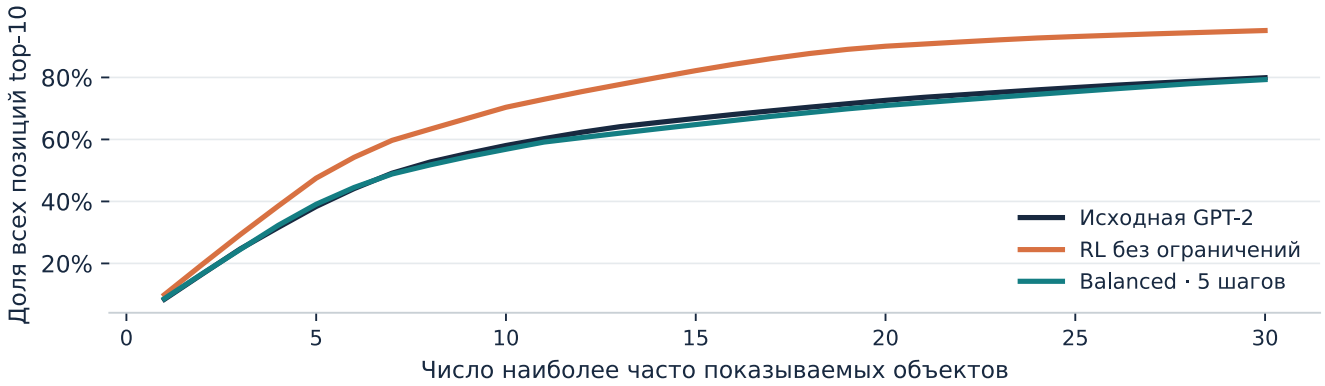
Слева — распределение наблюдаемого watch fraction. Справа — средний отклик в десяти квантильных бинах прогнозов; отрезки ±1,96 SE. Диагональ показывает идеальную калибровку среднего. Оценка только на наблюдаемых targets.

> RM немного лучше среднего объекта по MAE, но объясняет около 1,2% дисперсии. Хорошая возможность оптимизировать её прогноз не означает, что она стала надёжным симулятором пользовательских реакций.

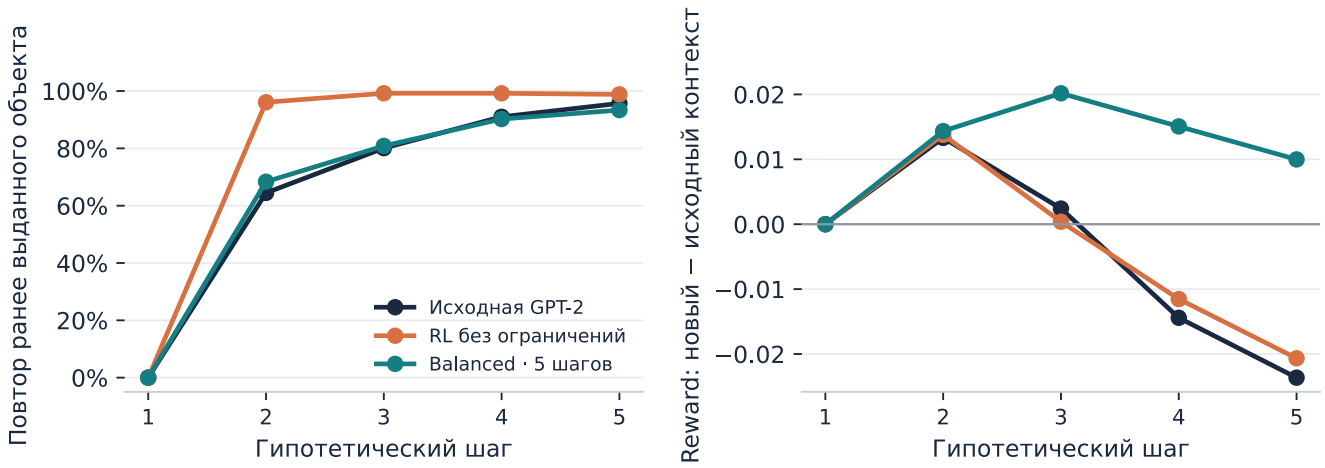
Return-head: AUC 0,5655, Brier 0,25044; train-prevalence константа даёт Brier 0,25064. Независимая инициализация auditor разделяет источник данных и может разделять его ошибки. По новым рекомендациям нет независимой ground truth.

Концентрация и гипотетические траектории

Без KL/CE ограничений один объект попадает в top-10 у **99,0%** пользователей против 84,2% у SFT. Покрытие каталога падает с 5,4% до 2,5%. Это измеряемое сужение выдачи, сопровождающее рост proxy.



Кумулятивная доля позиций top-10 у самых частых объектов. Для каждой политики объекты отсортированы по её собственной частоте. Чем выше кривая, тем сильнее концентрация.

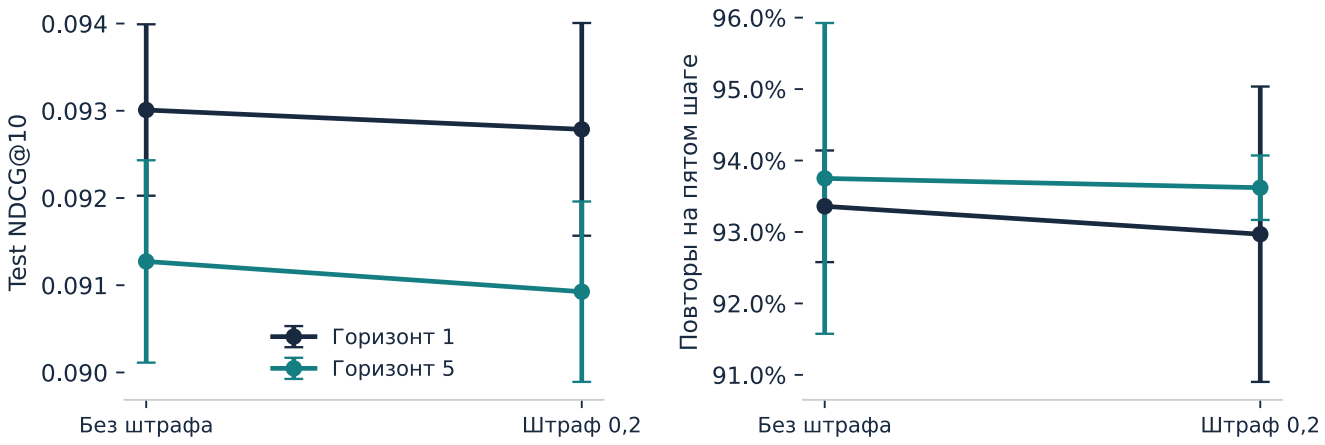


Пять greedy-шагов на 256 фиксированных контекстах. Повтор — объект уже появлялся в сгенерированном списке. Разность reward показывает чувствительность RM к гипотетическому контексту, не наблюдаемый долгосрочный возврат.

Сам объект не добавляется в реальную историю пользователя. Rollout делает это условно и потому всё дальше уходит от наблюдаемых переходов. Даже совпадение reward и auditor не доказывает реальный эффект.

Изоляция горизонта и штрафа за повтор

Чтобы разделить факторы, дополнительно обучены все четыре комбинации horizon 1/5 и штрафа за повтор 0/0,2. Штраф вычитается, если объект уже есть в текущем контексте из максимум 32 ID, включая ранее сгенерированные. Во всех клетках KL=0,1, CE=0,2 и 200 шагов. Три согласованных RL-запуска различаются сэмплированием и minibatches; SFT и RM заморожены.



Средние по трём RL-запускам; отрезки — их стандартное отклонение, не 95% CI. Справа оценивается повтор на пятом гипотетическом шаге для всех обученных политик.

Горизонт / штраф	NDCG · mean	SD между запусками	Watch-proxy	Повтор истории
1 / 0,0	0,09301	0,00098	0,54025	16,6%
1 / 0,2	0,09279	0,00122	0,54002	16,4%
5 / 0,0	0,09127	0,00116	0,54682	16,6%
5 / 0,2	0,09093	0,00103	0,54622	16,3%

Без штрафа переход с горизонта 1 на 5 меняет NDCG на **-0,00174**, CI [-0,00303; -0,00048]. Это условный результат при фиксированных SFT/RM и выбранных настройках, а не универсальное преимущество короткого горизонта.

Парные эффекты штрафа

Горизонт 1: изменение NDCG@10 при добавлении штрафа **-0,00022**, CI [-0,00109; 0,00063].

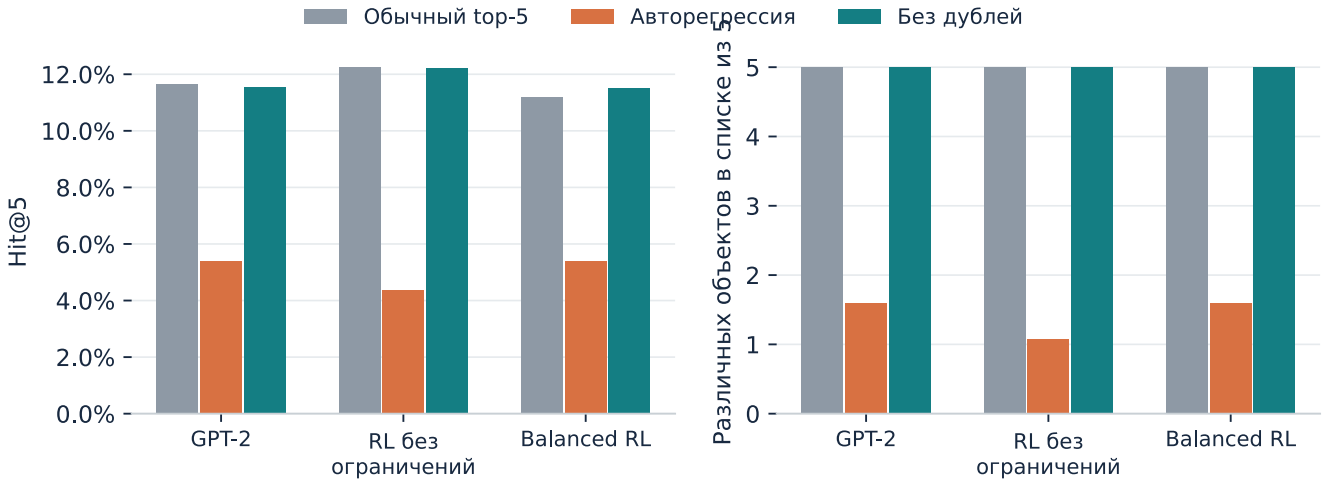
Горизонт 5: изменение NDCG@10 при добавлении штрафа **-0,00035**, CI [-0,00141; 0,00073].

Это дополнительный анализ после знакомства с исходным test. Все клетки опубликованы; новая primary model не выбирается. CI получены после усреднения per-user метрик по трём RL-запускам и bootstrap пользователей, условно на фиксированных SFT/RM и одной неделе.

Равно число обновлений, а не действий: horizon 1 генерирует 12 800 действий, horizon 5 — 64 000. Более длинный return также меняет масштаб gradient-сигнала. Отдельной нормализации по action budget здесь нет.

Что исправляет декодирование

Для трёх неизменных политик сравниваются обычный top-5 из одного состояния, пять авторегрессионных greedy-шагов и те же шаги с запретом уже сгенерированных объектов. Исторические просмотры дополнительно не маскируются; target при генерации не используется.



Одинаковые 2000 test-пользователей. Повторный target учитывается только в первой позиции его появления. Запрет дублей устраняет их по определению; это изменение декодирования, а не обученный эффект RL.

Политика	Декодирование	Hit@5	NDCG@5	Различных / 5
Исходная GPT-2	Обычный top-5	11,65%	0,07998	5,00
Исходная GPT-2	Авторегрессия	5,40%	0,04909	1,59
Исходная GPT-2	Без дублей	11,55%	0,07963	5,00
RL без ограничений	Обычный top-5	12,25%	0,07997	5,00
RL без ограничений	Авторегрессия	4,35%	0,04170	1,07
RL без ограничений	Без дублей	12,20%	0,07858	5,00
Balanced · 5 шагов	Обычный top-5	11,20%	0,07732	5,00
Balanced · 5 шагов	Авторегрессия	5,40%	0,04846	1,59
Balanced · 5 шагов	Без дублей	11,50%	0,07867	5,00

Запрет дублей восстанавливает большую часть потерь Hit@5 от авторегрессии. Но у RL без ограничений один объект остаётся в 99,25% уникальных списков: разнообразие внутри списка не гарантирует персонализацию между пользователями. Slate@5 — отдельная диагностика; она не заменяет исходный full-catalog@10.

Итоги исходного RL-эксперимента

Выводы

1. RL меняет поведение и увеличивает learned reward, но убедительный рост next-target релевантности не установлен.
2. Без ограничений усиливается концентрация; KL удерживает политику ближе к SFT. Результат зависит от функции reward и способа генерации.
3. Запрет дублей полезен для slate generation, однако сам по себе не исправляет одинаковые рекомендации разным пользователям.
4. RM и return-proxy недостаточны для доказательства роста удовлетворённости или удержания.

Практические ограничения

Один источник, дневные timestamps и агрегированные user–item пары; неизвестны показы и propensities. Нет независимой длительности объекта и исторических снимков метаданных. Повторные RL-запуски используют фиксированные SFT/RM; наблюдаемая устойчивость не покрывает все источники случайности. Для retention нужен онлайн A/B с длинным follow-up и guardrails по релевантности, повторам и концентрации.

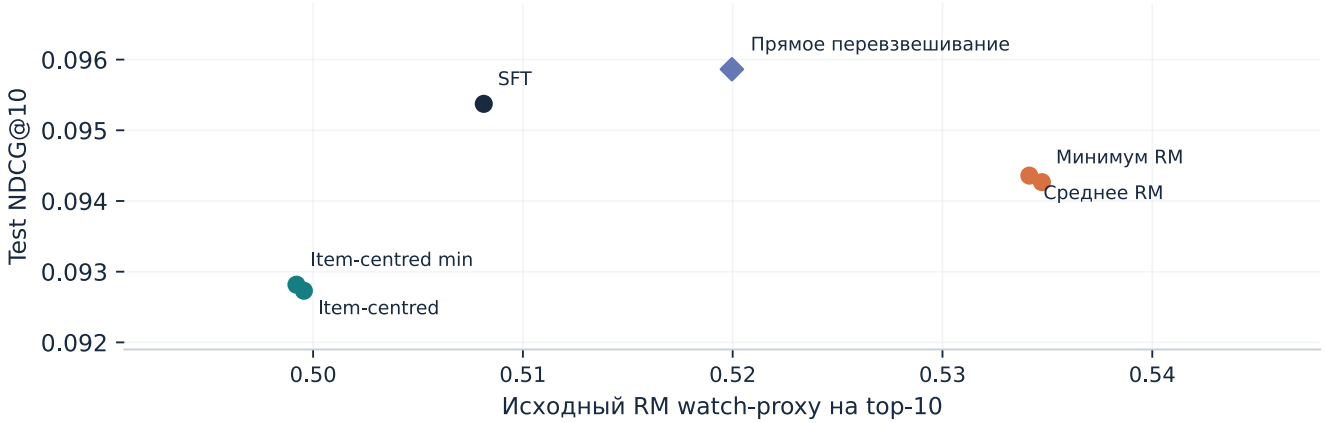
Воспроизведение

```
python reproduce.py task2
```

Окружение, параметры, CPU/GPU варианты и артефакты: README. Полные численные приложения: основной опыт, GPU-повторение. Все исходные результаты сохранены.

Можно ли исправить сам reward

Проверены среднее и минимум двух RM, а также вычитание item-only среднего прогноза по 256 реальным train-контекстам. Минимум — эвристический штраф за расхождение моделей, не калиброванная доверительная граница. Старый auditor входит в ensemble; третий monitor не участвует в оптимизации или выборе.



Фиксированные beta=0,1 диагностические RL-варианты и validation-selected аналитический контроль. Item-centred reward снижает концентрацию, но raw watch тоже падает. Оси используют один и тот же исходный RM.

Reward	NDCG	Watch	Max item
SFT	0,09537	0,50813	84,2%
Среднее RM	0,09436	0,53414	88,0%
Минимум RM	0,09427	0,53474	88,7%
Item-centred	0,09273	0,49956	81,8%
Item-centred min	0,09282	0,49921	81,8%

Шесть RL-настроек выбирались по validation watch при NDCG ≥99% SFT и росте max-item fraction не более 2 п.п. Правило сохранило SFT fallback; test не использован для выбора более удачной альтернативы.

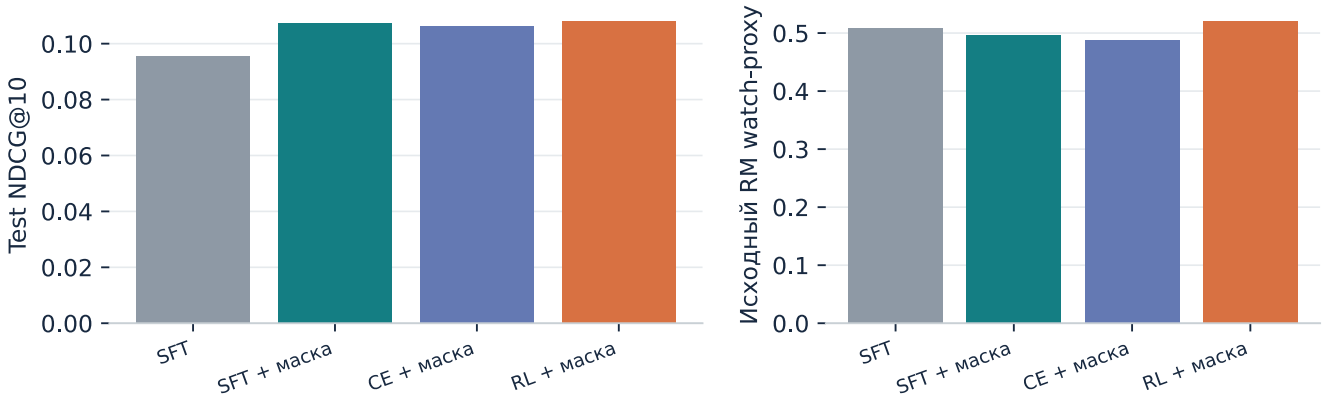
Контроль без дообучения

На фиксированном SFT top-100 распределение $q \propto p_{ref} \exp(\alpha r)$ точно решает условную one-step задачу reward − KL/α. Validation выбрала исходный reward и α=0,25. Это inference comparator, не дополнительная обученная RL-политика.

Test NDCG 0,09586, Δ 0,00049, CI [-0,00079; 0,00181]; watch 0,51996. Conditional KL≈0,00084; KL к полной SFT≈0,733 включает усечение support. Вне top-100 вероятность нулевая, поэтому NLL по таким targets не публикуется.

Отделяем допустимые действия от RL

В выпущенном KION user–item пары уникальны. Дополнительно исключаем IDs из известных последних 32 позиций. Для masked SFT и RL применяется одинаковая маска в sampling, loss и reference; target не используется. Ограничение соответствует этой задаче и требует отдельной проверки для повторного потребления.



SFT/continued-SFT — по одному frozen запуску, selected RL — среднее трёх повторных RL-запусков. Это средние отдельных политик, не ансамблирование их рангов. Нулевые повторы заданы support-ограничением.

Политика	NDCG	Recall	Max item
SFT	0,09537	0,16450	84,2%
SFT + маска	0,10734	0,17650	64,6%
CE + маска	0,10639	0,17400	64,6%
RL + маска	0,10786	0,17150	66,8%

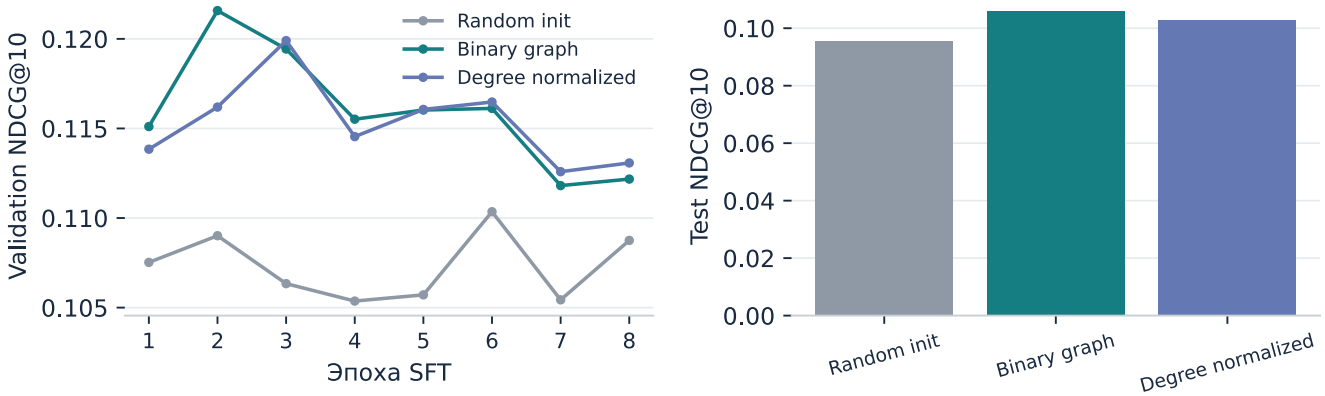
> Только маска даёт Δ NDCG **+0,01197**, CI [0,00951; 0,01439]. Поэтому рост относительно raw SFT нельзя целиком приписать RL.

Validation выбрала watch-RL с KL=0,5 и CE=0,2. Относительно masked SFT Δ NDCG 0,00052, CI [-0,00200; 0,00326]; Δ Recall -0,00500, CI [-0,00933; -0,00067]. Reward вырос, но сохранение NDCG не гарантирует сохранения Recall.

```
python -m task2.robust_reward
python -m task2.analytic_policy
python -m task2.history_mask
```

Обучаемые представления до RL

Раз сильные collaborative-признаки помогли бустингу, проверим их как начальные item embeddings GPT-2. SVD обучен только по train-графу; правые векторы умножаются на корень singular values и глобально масштабируются до RMS=0,02. Это дополнительный unsupervised этап, включая first-day/singleton edges вне supervised targets. Tied output embeddings сохраняются.



Для двух заранее заданных инициализаций и исходной SFT: та же архитектура, 100 000 переходов, восемь эпох. Checkpoint каждого run выбирается по validation.

Инициализация	NDCG	Recall	Покрытие
Исходная SFT	0,09537	0,16450	5,4%
Binary graph init	0,10588	0,17800	1,8%
Degree-normalized init	0,10280	0,17050	2,4%

Validation выбрала **Binary graph init**. Все заранее заданные варианты опубликованы, включая менее удачный. Это одно обучение SFT; интервалы по пользователям не покрывают вариативность инициализации и повторного обучения.

У binary init max-item fraction выросла до 93,5% против 84,2% у исходной SFT. Рост next-target точности здесь сопровождается более узким покрытием; это не улучшение всех свойств выдачи.

Binary graph init − original: Δ NDCG 0,01051, CI [0,00489; 0,01641].

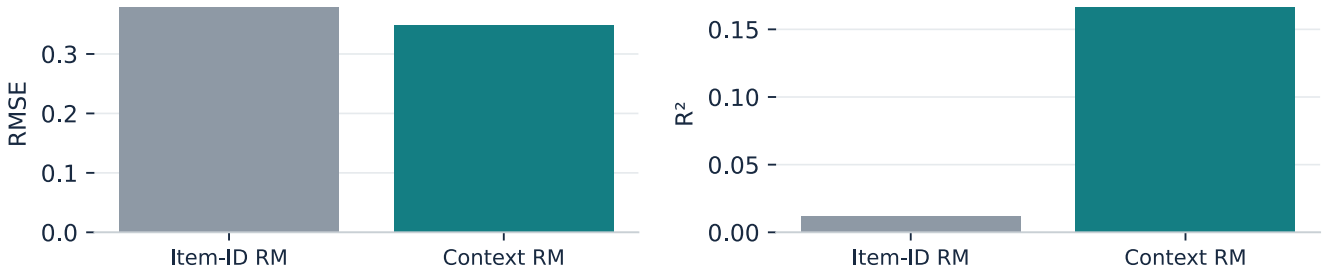
Degree-normalized init − original: Δ NDCG 0,00743, CI [0,00173; 0,01286].

Новая исходная модель не подставляется задним числом в старое RL-сравнение. Там reference и все выводы остаются исходными. Отдельное сравнение SFT/RL относительно нового reference проведено в завершающей главе.

```
python -m task2.graph_warmstart
```

Более точный прогноз отклика

Новая RM использует 32 признака: прошлые watched fractions, counts/recency по user, item и user–genre, окна 7/30/all и статические категории. Это больше информации, чем у исходной item-ID RM. Все агрегаты строго до дня target; same-day события исключены.



Те же 100 000 train и 2000 held-out примеров. CatBoost depth 4/6/8 выбран по validation RMSE; выиграл depth 6. Это совместное изменение архитектуры и доступных данных, не изолированное преимущество CatBoost.

Модель	MAE	RMSE	R²
Исходная RM	0,33567	0,37870	0,012
Context RM	0,29463	0,34789	0,166

Парное уменьшение MAE: 0,04104, CI [0,03465; 0,04750]. Важны предыдущая доля просмотра пользователя, режиссёр и статистики объекта. Это точность по наблюдаемым откликам; ошибки на непоказанных объектах остаются неизвестны.

Отбор RL по validation

Политика	NDCG	Recall	New RM watch
context_beta0.1	0,12290	0,20650	0,46683
context_beta0.5	0,12477	0,20700	0,46188
context_beta1	0,12459	0,20800	0,45900
Masked SFT	0,12639	0,21300	0,44536

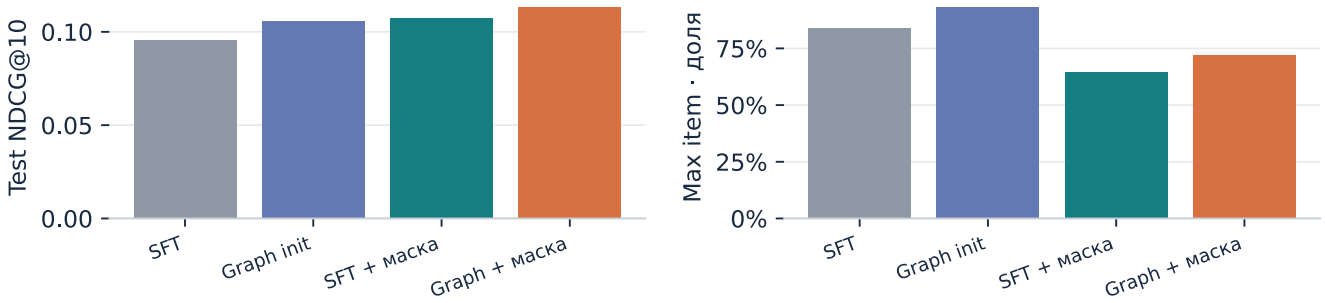
Новый one-step RL сравнивает KL=0,1/0,5/1 при CE=0,2 и одинаковой history mask. Validation ограничивает и NDCG, и Recall (≥99% SFT), а также концентрацию. Выбор: **masked_sft**. User/day для reward берутся из исходного batch; будущий отклик на sampled candidate не передаётся.

> Более высокий R² может отражать стабильную склонность пользователя досматривать, которую политика не управляет. Улучшение RM само по себе не доказывает улучшения рекомендаций или удержания.

Код: task2/context_reward.py, task2/context_rl.py. Все дополнения, CI и полные численные таблицы: приложение. Новые результаты exploratory; первоначальные CPU/GPU выводы сохранены.

Совмещаем проверенные компоненты

Завершающая проверка использует инициализацию, выбранную только по validation, и ту же маску последних 32 IDs. На этом reference заново обучаются три KL-варианта с более точной Context RM; ни старое, ни новое test-качество не определяет настройку.



Одинаковые исходные train transitions и test-пользователи. Каждый вариант SFT обучен один раз; повторных обучений всей системы здесь нет. Маска меняет допустимые действия, graph init — обучение исходной политики.

Компоненты	NDCG	Recall	Max item
SFT	0,09537	0,16450	84,2%
Graph init	0,10588	0,17800	93,5%
SFT + маска	0,10734	0,17650	64,6%
Graph + маска	0,11355	0,18550	72,2%

> Graph init + маска относительно исходной SFT: Δ NDCG **0,01818**, CI [0,01222; 0,02417]. Прирост относится к совмещению представлений и ограничения выдачи; его нельзя приписать RL.

Для RL с новой RM validation выбрала **masked_sft**. Ограничения одновременно проверяют NDCG, Recall и концентрацию. При fallback исходный reference сохраняется, даже если не прошедшая ограничения политика имеет более высокий predicted reward.

Что улучшилось и что остаётся открытым

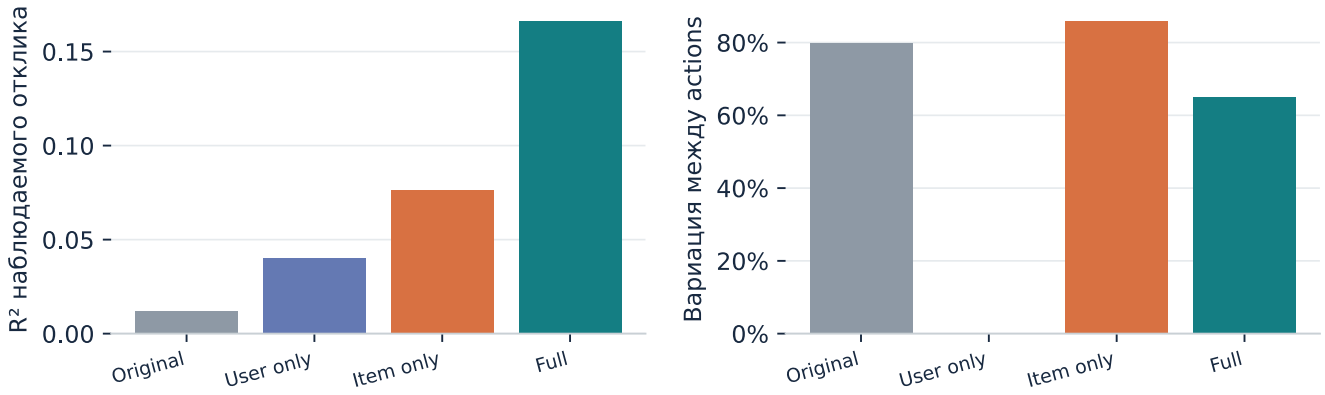
Представления и допустимое множество действий дают измеримый рост точности. Оптимизация reward по-прежнему требует контроля других метрик; более высокий R^2 и более высокий predicted reward не доказывают удовлетворённость. Дополнительные исследования уточняют исходный отрицательный RL-результат, сохраняя его протокол и все артефакты.

```
python reproduce.py task2
```

Команды всех дополнительных этапов: инструкция воспроизведения.

Точность RM и различение кандидатов

Проверим, объясняет ли более высокий R^2 лишь предсказуемость поведения пользователя. User-only RM использует 11 признаков без кандидата; item-only — 14 признаков без пользователя. Для обеих depth 4/6 выбирается по validation RMSE; full RM остаётся прежней.



Слева — качество на тех же наблюдаемых targets. Справа — доля predicted variance внутри каждого из 256 фиксированных контекстов на его SFT top-100, с одинаковыми весами кандидатов. Это не каузальная вариация отклика.

Информация	MAE	RMSE	R^2
Исходная RM	0,33567	0,37870	0,012
Только user	0,33906	0,37325	0,040
Только item	0,31659	0,36617	0,076
Полная Context RM	0,29463	0,34789	0,166

> Гипотеза «весь прирост точности объясняется только user propensity» не подтверждается: user-only и item-only заметно слабее full RM. Информация о контексте и кандидате полезна совместно.

Предсказуемое не всегда управляемо

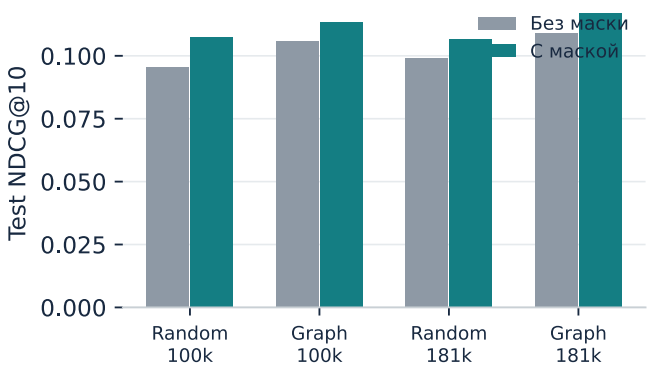
Если reward содержит b(s), одинаковое для всех действий, оно сокращается в leave-one-out advantage. User-only прогноз поэтому не даёт policy-gradient сигнала, каким бы точным он ни был. У full RM около 65% вариации в этой диагностике зависит от кандидата; это всё ещё не доказывает правильность оценок непоказанного контента.

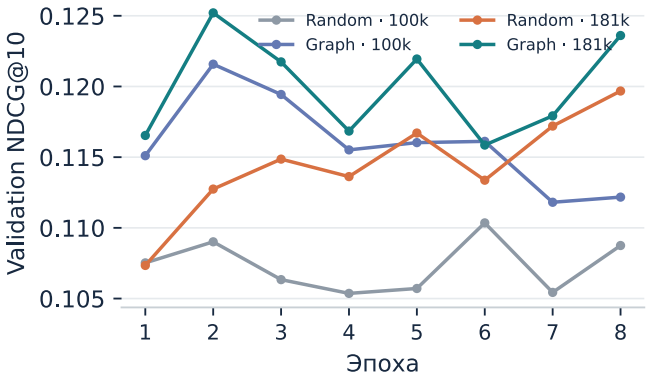
Межконтекстная вариация среднего также зависит от того, какие 100 кандидатов предложила SFT. Эти доли не разделяют причинный эффект пользователя и объекта. Слабый RL-результат нельзя объяснить одним state-only компонентом или исправить только повышением R^2.

```
python -m task2.reward_ablation
```

Контроль полного обучающего набора

Исходный SFT использовал лимит 100 000 переходов из 181 733 допустимых. Проверим, сохраняется ли польза graph init при обучении на полном train. Истории, словарь, архитектура и все validation/test targets неизменны. Повышение cap меняет RNG state, поэтому eval arrays загружаются из исходного опыта, а не генерируются заново.





Одинаковые восемь эпох; полный train даёт больше SGD updates, поэтому capped/full не изолируют только объём данных. Внутри каждой пары supervised budget одинаков. Граф дополнительно использует all-train-edge unsupervised SVD.

Train / init	Raw NDCG	Masked NDCG	Masked Recall
Random · 100k	0,09537	0,10734	0,17650
Graph · 100k	0,10588	0,11355	0,18550
Random · 181k	0,09895	0,10652	0,17800
Graph · 181k	0,10920	0,11680	0,19400

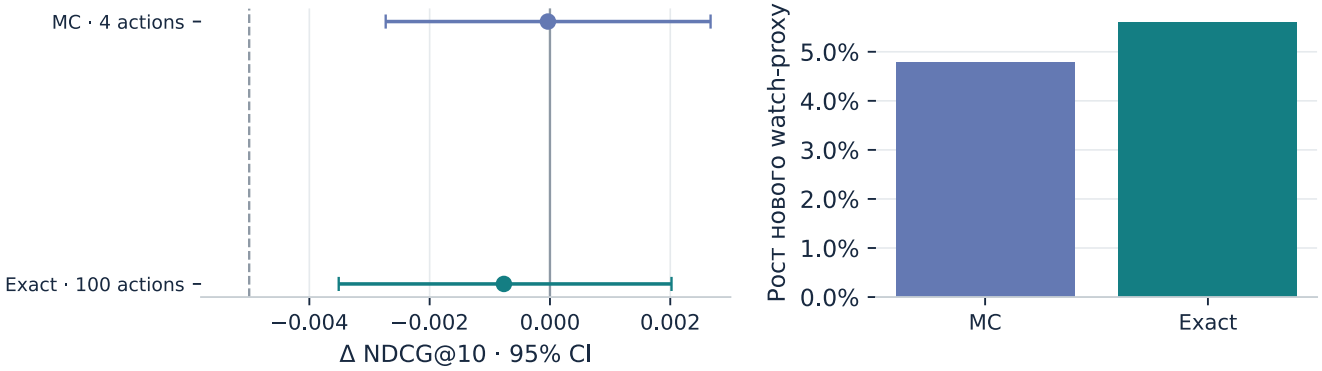
> Validation выбрала **full_graph_masked**. Внутри полного train graph − random с маской: Δ NDCG 0,01028, CI [0,00435; 0,01649]. Больше данных не улучшает каждую метрику автоматически: все восемь test-вариантов сохранены.

Одно обучение SFT на CPU; CI отражает вариативность пользователей. Отдельная GPU-проверка с тремя повторными обучениями в конце отчёта даёт более слабый masked gain. Singleton/first-day графовые edges доступны SVD даже без next-day target: это дополнительный unsupervised этап.

```
python -m task2.full_data_control
```

Сэмплированный и точный reward gradient

Сравниваем MC с четырьмя действиями и точный градиент ожидания по 100 действиям. Support задаёт усиленная frozen SFT, обученная на всех 181 733 переходах. History mask, 100k fine-tuning contexts, batches, 200 updates, lr=3·10⁻⁵, KL=0,5 и CE=0,2 совпадают; три согласованных RL-запуска.



Среднее per-user по трём RL-запускам, затем bootstrap пользователей; SFT/RM фиксированы. Пунктир слева — диагностическая граница потери 0,005, заданная до новых результатов. Справа — predicted reward, не наблюдаемый отклик.

Градиент	NDCG	Recall	New RM watch	Max item
Reference	0,11680	0,19400	0,42568	69,5%
MC · 4 actions	0,11677	0,19250	0,44601	71,7%
Exact · 100 actions	0,11604	0,19067	0,44953	72,2%

> Оба метода повышают proxy при небольшой тестовой потере NDCG. Однако строгий validation-отбор по NDCG и Recall ≥99% reference отклонил оба варианта. Reference сохраняется; test не используется для отмены этого решения.

Условные test CI укладываются в заранее заданную границу −0,005. Это исследовательская диагностика на уже обсуждавшемся тесте, а не универсальная гарантия неухудшения. Exact gradient не оказался автоматически лучше Monte Carlo по релевантности.

Цена и пределы точного ожидания

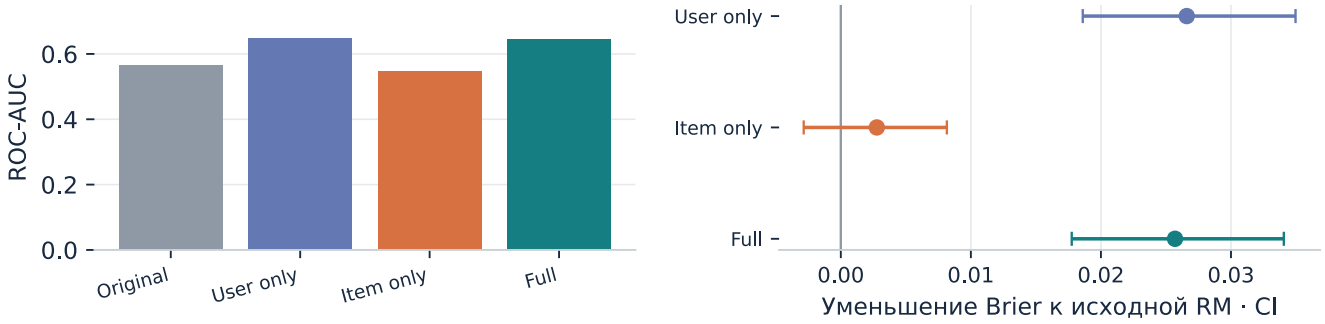
Reward/reference таблица общая и предвычислена по 100 кандидатам, поэтому это не сравнение чистой стоимости 4 и 100 вызовов RM. Оптимизируется условный top-100 surrogate; output и exact KL используют весь каталог. Проверка на capped reference также оставила SFT fallback.

Несовпадение целей. Watch-weighted средний target NDCG: reference 0,13770, MC 0,14166, exact 0,14174. На validation прирост слабее, CI пересекают ноль. Это post-hoc диагностика записанной цели, не reward нового списка. Test · validation; исходный выбор не меняется.

```
python -m task2.conditional_bandit --full-reference \
  --out artifacts/task2_conditional_full_reference
```

Прогноз следующего активного дня

Цель — следующий записанный активный день в течение трёх суток. Неполные окна цензурируются по исходному правилу; на test остаётся 1285 наблюдений. Используются прежние point-in-time признаки, depth 4/6 и выбор по validation Brier. Все предписанные модели опубликованы.



Те же censoring masks и target rows, что у исходной нейросетевой RM. Brier improvement считается парно по наблюдаемым пользователям. Дополнительные категории и статистики расширяют информацию относительно исходного item-ID RM.

Модель	AUC	Brier	LogLoss
Train prevalence	0,500	0,25064	0,69444
Исходная RM	0,566	0,25044	0,69544
Только user	0,648	0,22384	0,63916
Только item	0,545	0,24767	0,68843
Полная Context RM	0,644	0,22474	0,64093

> Возвращение предсказывается заметно лучше исходной RM, но user-only модель почти так же точна, как full. Ей не нужен рекомендуемый объект: высокая предсказуемость состояния ещё не даёт управляемой цели для политики.

Что можно проверить офлайн

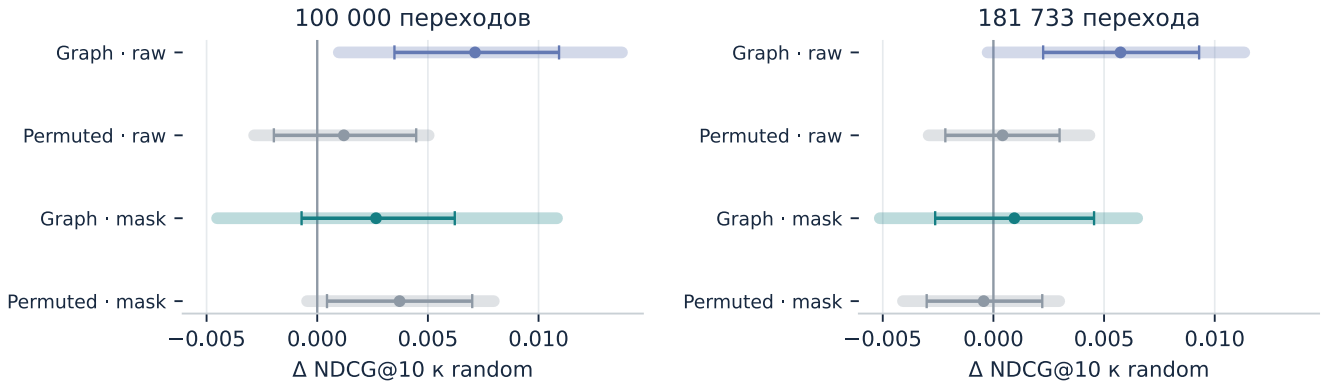
Можно измерить качество proxy, калибровку, чувствительность к информации о кандидате и поведение политики. В этих данных не наблюдаются все визиты: «возврат» означает следующий день новой записанной user–item пары, а не полный журнал посещений.

Предсказанный return не оценивает причинный эффект конкретной рекомендации. Для вывода об удержании нужны логи показов/реакций и онлайн-эксперимент с длинным follow-up.

```
python -m task2.return_reward
```

Устойчивость графовой инициализации

18 самостоятельных SFT fits на Tesla T4: два объёма train, три способа инициализации и три повторных обучения. По восемь эпох; массивы train/validation/test проверены SHA. Перестановка строк graph initializer сохраняет его распределение, но разрушает item alignment, включая popularity.



Тонкие интервалы — bootstrap пользователей после усреднения трёх запусков. Полупрозрачные — sensitivity с совместным пересэмплированием тех же запусков и пользователей. Всего три запуска; оценка всей вариативности обучения ограничена.

Train / init	Raw NDCG ± SD	Masked NDCG ± SD	Max item · mask
100k · Random	0,09599 ± 0,00229	0,10790 ± 0,00385	67,3%
100k · Graph	0,10312 ± 0,00290	0,11055 ± 0,00407	69,8%
100k · Permuted	0,09719 ± 0,00222	0,11162 ± 0,00328	72,7%
181k · Random	0,09793 ± 0,00204	0,10892 ± 0,00368	66,8%
181k · Graph	0,10368 ± 0,00426	0,10987 ± 0,00398	65,1%
181k · Permuted	0,09835 ± 0,00319	0,10848 ± 0,00334	66,6%

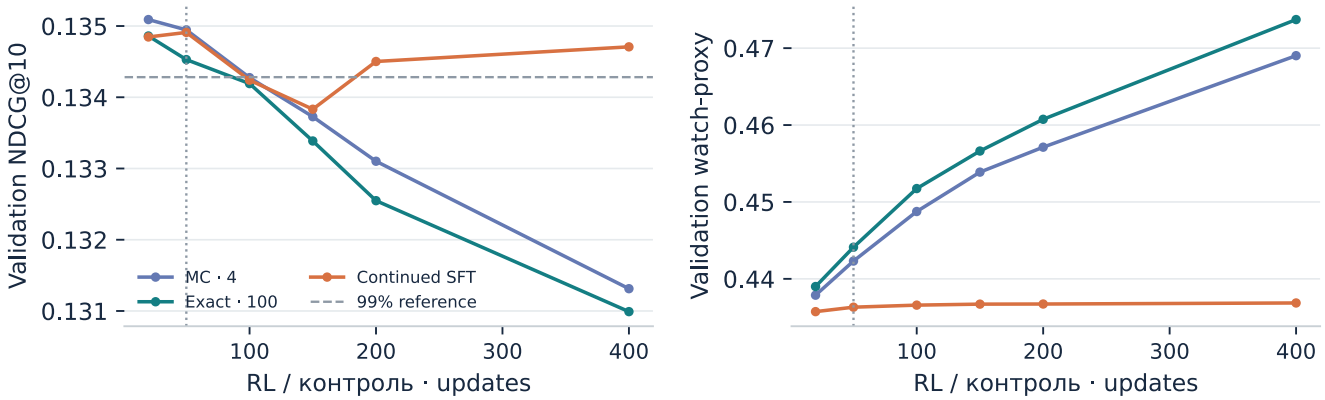
> Graph улучшает raw NDCG во всех трёх запусках при обоих cap; validation выбирает graph. После маски его дополнительный gain мал, CI пересекают ноль. Удачный результат одного CPU-запуска не представляет средний эффект.

Permuted raw близок к random; masked permuted конкурентен graph. Это не чистая абляция семантики. CPU и GPU используют разные Torch/device, поэтому результаты приведены отдельно. Те же уже изученные test users; нового внешнего подтверждения нет.

Таблицы отдельных запусков и параметры воспроизведения сохранены в приложениях и инструкции.

Момент остановки меняет компромисс

Отказ fixed200 не исключает более короткую оптимизацию. До новых результатов заданы 20/50/100/150/200/400 updates для MC и exact. Все настройки, три повторных RL-запуска и minibatches прежние; дополнительно обучается continued-SFT с теми же CE/KL, но без reward gradient.



Средние трёх RL-запусков, SFT/RM фиксированы. Пунктир — ограничение NDCG; выбор также требует Recall ≥99% reference и max-item ≤reference+0,02. Контроль не участвует в выборе RL. Вертикаль — выбранный шаг.

Политика	NDCG	Recall	Watch-proxy	Max item
Continued SFT · 50	0,11716	0,19483	0,42646	69,2%
RL · exact · 50	0,11721	0,19500	0,43401	70,5%
Reference	0,11680	0,19400	0,42568	69,5%

> Validation выбрала **exact, 50 updates**. Test watch-proxy вырос на 2,0%; Δ NDCG 0,00040, CI [-0,00119; 0,00196]. Относительно matched continued-SFT Δ 0,00005, CI [-0,00130; 0,00141]: убедительного выигрыша точности нет.

Шесть RL checkpoints на шаге 200 бит-в-бит совпали с прежними fixed200 моделями. Выбор method/step захеширован до test; test оценивает только reference, выбранный RL и matched контроль. Двенадцать новых вариантов используют ту же validation, поэтому это дополнительный exploratory поиск, а CI не охватывают uncertainty выбора.

Ранняя остановка позволяет небольшой рост predicted reward при близкой релевантности. Ни этот proxy, ни сохранение NDCG не доказывают улучшения реального отклика или удержания.

```
python -m task2.validation_path
```

Полные настройки, curves, CI и воспроизведение.